

注：图中部分REQUANT是在上一层内进行的，例如Quant Plus后的REQUANT；部分REQUANT是在单独进行的，例如Layernorm后的REQUANT；

